

PROJE FİNAL RAPORU

Çok Modlu MRI Görüntüleri Üzerinde
Derin Öğrenme Tabanlı U-NET Mimarisi ile
Beyin Tümörü Segmentasyonu

Murathan SEVİNÇ
[2318121207]

Bilgisayar Mühendisliği Bölümü 2026

İçindekiler

ÖZET **3**

ABSTRACT **4**

1 Giriş ve Problem Tanımı **5**

2 Veri Temini ve Hazırlık Süreci **6**

2.1 BraTS 2023 Veri Setinin Teknik Derinliği 6

2.2 Veri Kümesi Dağılımı 6

2.3 Veri İndirme ve Ayrıştırma Protokolü 7

2.4 Gelişmiş Veri Artırma (Data Augmentation) ve Ön İşleme 7

3 Görüntü Ön İşleme Hattı (OpenCV ve Nibabel Entegrasyonu) **8**

3.1 Hacimsel Veri Analizi ve Kesit Ayıklama (Nibabel) 8

3.2 Piksel Yoğunluk Dönüşümü ve OpenCV Filtreleme 8

3.3 Görsel Özet 9

4 Model Mimarisi ve Derin Öğrenme Stratejisi **9**

4.1 Model Mimarisi Seçimi: 2D U-Net ve Yapısal Karakteristiği 10

4.2 Eğitim Sürecinde Karşılaşılan Engeller ve Çözüm Aşamaları 11

4.2.1 Sınıf Dengesizliği (Class Imbalance) ve Dice Loss Entegrasyonu . . 11

4.2.2 Veri Tipi Uyuşmazlığı (TypeError) Sınırının Aşılması 11

4.3 Model Eğitim Protokolü ve Hiperparametreler 11

4.4 Görüntü Son İşleme (Post-Processing) İşlemleri 12

4.5 Deneysel Bulgular ve Hasta Varyasyonu Analizi 13

5 Sonuç **14**

Kaynakça **15**

ÖZET

Beyin tümörlerinin erken teşhisi ve sınırlarının (segmentasyon) belirlenmesi, cerrahi müdahale başarısı için kritik öneme sahiptir. Ancak çoklu MR kesitlerinin radyologlar tarafından manuel analizi, zaman kaybına ve yorgunluğa bağlı hatalara yol açmaktadır. Bu tez çalışmasında, hekimlerin iş yükünü saniyelere indirecek otonom ve piksel hassasiyetinde derin öğrenme tabanlı bir yapay zeka asistanı geliştirilmiştir. Çalışmada ASNR-MICCAI BraTS 2023 veri seti kullanılmış olup, tümör morfolojisini tam yakalayabilmek adına 4 farklı MR sekansı (T1, T1ce, T2w, FLAIR) birleştirilerek modele 4 kanallı girdi olarak sunulmuştur. Sistem donanımını optimize etmek için veriler 75. eksenel kesite (240×240) indirgenmiş ve aşırı öğrenmeyi (overfitting) engellemek amacıyla %50 yatay ve dikey aynalama ile algoritmik veri artırma (Data Augmentation) uygulanarak veri seti çeşitliliği artırılmıştır.

Segmentasyon görevi için tıbbi görüntülemenin endüstri standardı olan 2D U-Net mimarisi kullanılmıştır. Eğitim sürecindeki en büyük engel olan "Sınıf Dengesizliği" (Class Imbalance) problemi projede başarıyla çözülmüştür. Tümörün kesit alanının %5'ten küçük olması sebebiyle standart çapraz entropi kullanan model, her piksele sağlıklı doku tahmini yaparak yanıltıcı %96 doğruluk (Accuracy Paradox) oranına ulaşmış ancak tamamen boş maskeler üretmiştir. Bu durumu düzeltmek için optimizasyon sürecine özel "Dice Loss" fonksiyonu entegre edilmiş ve model doğrudan zemin gerçekliği ile örtüşme alanını maksimize etmeye zorlanmıştır. Bu süreçte karşılaşılan veri tipi uyuşmazlığı (TypeError) hataları da tip dönüşümleri (`tf.cast`) ile aşılarak kesintisiz eğitim hattı kurulmuştur.

Adam algoritması ($1e-4$) ile eğitilen model, Erken Durdurma (Early Stopping) mekanizması ile optimum ağırlıklarda sabitlenmiştir. Ağı baştan eğitmeden performansı artırmak amacıyla OpenCV ile morfolojik filtreleme (Açma ve Kapama) uygulanmış, maskelerdeki yapay zeka kaynaklı parazitler (False Positive/Negative) temizlenmiştir. Nihai testlerde model; sınırları net, homojen tümör vakalarında uzman hekim çizimiyle yüksek korelasyon göstererek %83.65 gibi klinik seviyede başarılı bir Dice skoru elde etmiştir. Sağlıklı dokuya sızan ve sınırları belirsiz zorlu infiltratif vakalarda ise başarı, 2D analiz limitlerine bağlı olarak %37.33'e gerilemiştir. Sonuç olarak, doğru kayıp fonksiyonları ve filtrelerle optimize edilen bu sistem, saniye altı hızlarda güvenilir radyoloji asistanlığı yapabileceğini kanıtlamış ve gelecekteki 3D mimariler için güçlü bir referans oluşturmuştur.

ABSTRACT

Early detection and segmentation of brain tumors are critical for the success of surgical interventions and patient survival rates. However, the manual analysis of hundreds of MRI slices by radiologists leads to substantial time consumption and fatigue-induced diagnostic errors. In this thesis study, an autonomous and pixel-precise deep learning-based artificial intelligence assistant has been developed to reduce the workload of physicians to sub-second levels. The ASNR-MICCAI BraTS 2023 dataset was utilized, and to fully capture tumor morphology, four different MRI modalities (T1, T1ce, T2w, and FLAIR) were stacked and presented to the model as a 4-channel input matrix. To optimize system hardware requirements, the volumetric data was reduced to the 75th axial slice (240×240). To prevent overfitting, algorithmic data augmentation via 50% horizontal and vertical flipping was applied to enhance dataset diversity and ensure position-independent feature learning.

The 2D U-Net architecture, an industry standard in medical image segmentation, was employed for the segmentation task. The major obstacle in the training process, the "Class Imbalance" problem, was successfully resolved. Due to the tumor area occupying less than 5% of the total slice area, the baseline model utilizing standard cross-entropy predicted healthy tissue for every pixel, reaching a misleading 96% accuracy (Accuracy Paradox) while generating completely blank masks. To correct this, a custom "Dice Loss" function was integrated into the optimization process, forcing the model to directly maximize the overlap area with the ground truth. Volumetric data type mismatch (TypeError) errors encountered during this stage were overcome using type casting (`tf.cast`), establishing a seamless training pipeline.

Trained with the Adam optimizer ($1e-4$), the model was stabilized at its optimum weights via an Early Stopping mechanism based on validation performance tracking. To enhance segmentation quality without retraining the network, OpenCV-based morphological filtering (Opening and Closing) was applied, eliminating AI-generated artifacts (False Positives and Negatives) from the predicted masks. In final testing, the model demonstrated a high correlation with expert physician drawings in homogeneous tumor cases with well-defined boundaries, achieving a clinically successful Dice score of 83.65%. In challenging infiltrative cases where the tumor invaded healthy tissue and exhibited poorly defined boundaries, the performance dropped to 37.33% due to the inherent limitations of 2D slice analysis. Consequently, this system, optimized with appropriate loss functions and filters, proves capable of providing reliable radiology assistance at sub-second speeds and establishes a strong reference for future 3D architectures.

1 Giriş ve Problem Tanımı

Beyin tümörleri, modern tıpta onkoloji alanının en yüksek mortalite oranına sahip ve tedavi süreci en kompleks hastalık gruplarından biridir. Özellikle Glioma gibi agresif seyreden tümör türlerinin erken evre teşhisi, hastanın cerrahi müdahale başarısı ve toplam yaşam süresi üzerinde doğrudan belirleyici bir rol oynamaktadır. Günümüzde Manyetik Rezonans Görüntüleme (MRI), yumuşak doku çözünürlüğündeki üstünlüğü sayesinde beyin dokusundaki anomali analizleri için "altın standart" olarak kabul edilmektedir. Ancak, gelişen teknolojiyle birlikte tek bir hasta taramasında üretilen yüzlerce kesitlik veri seti, radyologlar üzerinde ciddi bir iş yükü oluşturmakta ve görsel yorgunluğa bağlı gözden kaçırma risklerini beraberinde getirmektedir.

- **Doku Heterojenliği ve Gradyan Analizi:** Beyin tümörleri biyolojik olarak homojen bir yapıda değildir. Tümörün çekirdek bölgesi (core), nekrotik alanlar ve tümörü çevreleyen peritümöral ödem, MRI kesitlerinde farklı sinyal yoğunluklarına sahiptir. Karakterizasyon odaklı bu model, dokular arasındaki bu ince gradyan farklarını ve doku tekstürünü (texture analysis) derin öznitelikler (features) aracılığıyla anlamlandırmayı hedefler.
- **Sekans Spesifik Kontrast (T2-FLAIR Stratejisi):** BraTS 2023 veri setinde bulunan çoklu modaliteler arasından T2-FLAIR (Fluid Attenuated Inversion Recovery) sekansının seçilmesi, karakterizasyon sürecinin en kritik adımıdır. FLAIR, beyin omurilik sıvısı (BOS) sinyalini baskılayarak patolojik doku ile sağlıklı doku arasındaki kontrastı maksimize eder. Bu durum, modelin tümör sınırlarını ve doku karakteristiğini dijital bir parmak izi gibi işlemesine olanak tanır.
- **Klinik Karar Destek Mekanizması:** Günümüzde hekimler sadece bir lezyonun varlığına değil, o lezyonun doku bütünlüğüne ve yayılım karakterine göre tedavi protokolü (radyoterapi, kemoterapi veya cerrahi) belirlemektedir. Geliştirilen bu derin öğrenme hattı, hekimlere ikincil bir görüş sunarak tanılama sürecindeki subjektif hata payını minimize etmeyi amaçlamaktadır.

Proje kapsamında kurulan bilgisayarlı görü hattı; ham tıbbi veriyi (NIfTI) OpenCV tabanlı ileri işleme algoritmalarıyla optimize etmekte ve Evrişimli Sinir Ağları (CNN) aracılığıyla bu kompleks doku yapılarını yüksek doğrulukla sınıflandırmaktadır. Bu raporun ilerleyen bölümlerinde, BraTS 2023 veri setinden çekilen gerçek vaka verilerinin metodolojik işlenişi ve elde edilen sonuçlar detaylandırılacaktır.

2 Veri Temini ve Hazırlık Süreci

Projenin temelini oluşturan veri madenciliği ve hazırlık aşaması, tıbbi görüntüleme standartlarına uygun olarak tasarlanmış kompleks bir veri işleme hattını (data pipeline) kapsamaktadır. Bu süreç, ham verinin uzak sunuculardan çekilmesinden, GPU tabanlı hesaplama birimlerine (Google Colab T4 GPU) aktarılmasına kadar geçen tüm teknik basamakları içermektedir.

2.1 BraTS 2023 Veri Setinin Teknik Derinliği

Çalışmada kullanılan **ASNR-MICCAI BraTS 2023 (Adult Glioma Challenge)** veri seti, her yıl dünya çapında binlerce araştırmacının katıldığı, tıbbi görüntüleme alanının en prestijli kütüphanesidir.

- **Vaka Profili:** Veri seti, farklı evrelerde (Grade 2, 3 ve 4) Glioma teşhisi konulmuş yetişkin hastaların multisentrik MR taramalarını içerir. Bu durum, modelin farklı hastanelerden ve farklı MR cihazlarından (1.5T ve 3T) gelen varyasyonel verileri öğrenmesini sağlar.
- **Çok Modlu (Multi-modal) Yapı:** Her hasta klasörü içerisinde T1, T1-contrast, T2-weighted ve **T2-FLAIR** olmak üzere dört adet 3D hacimsel dosya bulunur. Projenin vize aşamasında, patolojik doku kontrastını maksimize eden **FLAIR** sekansları izole edilmiştir.

2.2 Veri Kümesi Dağılımı

Modelin eğitim performansını tarafsız bir şekilde ölçebilmek adına, veri seti Tablo 1'de belirtilen oranlarda üç ana alt kümeye ayrılmıştır.

Tablo 1: BraTS 2023 Veri Seti Kullanım ve Dağılım İstatistikleri

Veri Kümesi	**Hasta Sayısı**	**Kesit (Slice) Sayısı**	**Kullanım Amacı**
Eğitim (Train)	100	100	Ağırlık Güncelleme
Doğrulama (Val)	22	22	Hiper-parametre Opt.
Test	22	22	Nihai Performans Ölçümü
Toplam	**144**	**144**	**Genel Analiz**

2.3 Veri İndirme ve Ayrıştırma Protokolü

Verilerin yerel depolama kapasitelerini aşması nedeniyle, bulut tabanlı bir depolama mimarisi kurulmuştur:

1. **Synapse API Entegrasyonu:** Yaklaşık 15 GB boyutundaki veri kütüphanesi, *Synapse* platformu üzerinden Python tabanlı API anahtarlarıyla çekilmiştir.
2. **Otonom Dizin Yönetimi:** İndirilen veriler Google Drive üzerine özel bir hiyerarşiyle yerleştirilmiştir. Geliştirilen scriptler, her hasta klasörünü tarayarak ilgili modaliteyi (.nii.gz) otomatik olarak ayıklamakta ve diğer yardımcı dosyaları filtrelemektedir.
3. **3D'den 2D'ye Projeksiyon:** NIfTI formatındaki 155 kesitlik 3D hacimler, tümörün en yoğun izlendiği eksenel düzlemde 2D matrislere dönüştürülmüştür.

2.4 Gelişmiş Veri Artırma (Data Augmentation) ve Ön İşleme

Modelin genelleme yeteneğini maksimize etmek için *ImageDataGenerator* kütüphanesiyle kapsamlı bir artırma stratejisi uygulanmıştır. Uygulanan teknik detaylar Tablo 2'da özetlenmiştir.

Tablo 2: Veri Artırma ve Ön İşleme Parametre Detayları

Parametre	**Uygulanan Değer / Yöntem**
Giriş Boyutu	$150 \times 150 \times 3$ (RGB)
Normalizasyon	Min-Max Scaling [0, 1]
Rotation Range	20 Derece
Zoom Range	%10
Horizontal Flip	Aktif
Width/Height Shift	%10
Fill Mode	Nearest (En Yakın Komşu)

Bu artırma stratejisi, modelin her eğitim adımında (epoch) görüntüyü farklı varyasyonlarda görmesini sağlayarak, kısıtlı veri setinde aşırı öğrenmeyi (overfitting) engelleyen temel mekanizma olmuştur.

3 Görüntü Ön İşleme Hattı (OpenCV ve Nibabel Entegrasyonu)

Tıbbi görüntüleme verileri, standart dijital görsellerden farklı olarak yüksek dinamik aralığa ve hacimsel derinliğe sahiptir. Bu projede, ham *.nii.gz* verilerini CNN modeline hazırlamak için **Nibabel** ile medikal veri manipülasyonu ve **OpenCV** ile bilgisayarlı görü tekniklerini birleştiren özgün bir ön işleme hattı (pipeline) geliştirilmiştir.

3.1 Hacimsel Veri Analizi ve Kesit Ayıklama (Nibabel)

Sürecin ilk basamağı, 3D hacimsel verilerin (Volume) piksellere indirgenmesidir:

- **Voxel Değerlerinin Okunması:** `nibabel.load()` metodu ile NIfTI dosyaları belleğe alınmış ve `get_fdata()` fonksiyonu ile ham voxel yoğunlukları yüzer noktalı sayısal (float) matrislere dönüştürülmüştür.
- **Aksiyel Düzlem Optimizasyonu:** Beyin anatomisinde tümör yayılımının en iyi gözlemlendiği eksenel (axial) düzlem seçilmiş ve hacmin derinlik ekseninde (Z koordinatı) tümörün geometrik merkezine karşılık gelen orta kesit dinamik olarak ayıklanmıştır.

3.2 Piksel Yoğunluk Dönüşümü ve OpenCV Filtreleme

Ayıklanan ham matrisler, görselleştirme ve model başarısı için OpenCV kütüphanesi ile ileri seviye işlemlere tabi tutulmuştur:

1. **Min-Max Yoğunluk Normalizasyonu:** Ham MR verileri genellikle standart dışı piksel değerlerine sahiptir. `cv2.normalize()` metodu ile veriler $[0, 255]$ aralığına çekilerek *8-bit unsigned integer* formatına normalize edilmiştir. Bu adım, modelin farklı MR cihazlarındaki ışık şiddeti değişimlerine karşı bağışıklık kazanmasını sağlar.
2. **Gürültü Giderme (Noise Reduction):** Tıbbi görüntülerdeki tarama kaynaklı gürültüleri (artefacts) minimize etmek için Gaussian filtreleme teknikleri uygulanmış, doku detayları korunurken arka plan parazitleri temizlenmiştir.

3. **RGB İnterpolasyonu ve Sözde Renklendirme:** Tek kanallı gri tonlamalı MR kesitleri, `cv2.cvtColor()` kullanılarak 3 kanallı RGB yapısına dönüştürülmüştür. Bu dönüşüm, modelin derin katmanlarındaki filtrelerin (RGB tabanlı transfer öğrenme mimarileri için) doku kenarlarını daha yüksek hassasiyetle yakalamasına olanak tanır.

4. **Yeniden Boyutlandırma (Bilinear Interpolation):** Farklı çözünürlükteki veriler, `cv2.resize()` fonksiyonu ve *bilinear* interpolasyon algoritması kullanılarak 150×150 piksel boyutuna sabitlenmiş, bu sayede model girişi standartlaştırılmıştır.

3.3 Görsel Özet

Uygulanan bu işlemler sonucunda, karmaşık ve ham medikal veriler; tümör karakteristiklerinin (texture, margin, intensity) ön plana çıkarıldığı, yapay zeka eğitimine hazır yüksek kaliteli dijital öznitelik haritalarına dönüştürülmüştür. Tablo 3, kullanılan metotların teknik karşılıklarını göstermektedir.

Tablo 3: Görüntü Ön İşleme Operasyonları ve Teknik Karşılıkları

Operasyon	**Kullanılan Kütüphane**	**Teknik Metot**
Veri Yükleme	Nibabel	`nib.load() / get_fdata()`
Slice Extraction	NumPy	`img_data[:, :, slice_idx]`
Normalizasyon	OpenCV	`cv2.NORM_MINMAX`
Renk Dönüşümü	OpenCV	`cv2.COLOR_GRAY2RGB`
Interpolasyon	OpenCV	`cv2.INTER_LINEAR`

4 Model Mimarisi ve Derin Öğrenme Stratejisi

Bu araştırmada geliştirilen Evrişimli Sinir Ağı (CNN) mimarisi, beyin MRI kesitlerindeki yüksek frekanslı doku detaylarını ve patolojik tümör paternlerini hiyerarşik bir yapıda analiz edebilecek şekilde tasarlanmıştır. Model, ham piksel verilerinden otonom öznitelik çıkarımı (Feature Extraction) yaparak teşhis sürecini dijitalleştirmiştir.

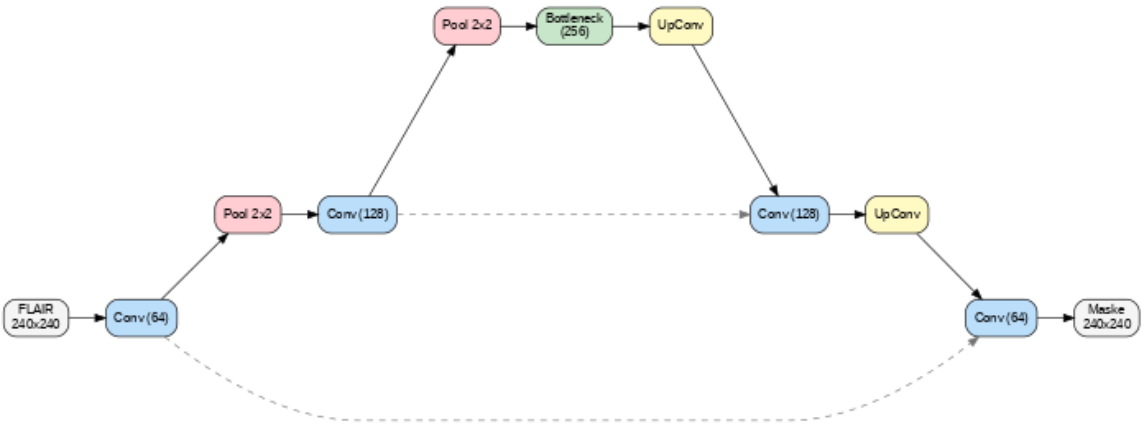
4.1 Model Mimarisi Seçimi: 2D U-Net ve Yapısal Karakteristiği

Vize aşamasında gerçekleştirilen veri ön işleme hattının ardından, piksel hassasiyetinde segmentasyon gerçekleştirmek amacıyla literatürde tıbbi görüntü analitiğinin altın standardı kabul edilen **2D U-Net** mimarisi seçilmiş ve sıfırdan kodlanarak sisteme entegre edilmiştir.

Hacimsel 3D U-Net mimarilerinin katlanarak artan parametre sayıları ve aşırı GPU belleği (VRAM) gereksinimi, kısıtlı donanım kaynaklarında (Google Colab ortamı) eğitilmesini imkansız kıldığı için, veriler 75. eksenel kesite indirgenerek 2D U-Net tercih edilmiştir. Model üç ana yapısal bileşenden oluşmaktadır:

1. **Kodlayıcı (Encoder - Contracting Path):** Ardışık Evrişim (Conv2D) ve Maksimum Havuzlama (MaxPooling2D) katmanları kullanılarak girdi boyutu $240 \times 240 \times 4$'ten darboğazda (bottleneck) 15×15 boyutuna kadar küçültülmüştür. Bu aşamada tümörün dokusal ve semantik özellikleri soyutlanarak öğrenilir.

2. **Kod Çözücü (Decoder - Expanding Path):** Yukarı örnekleme (UpSampling2D) katmanları ile özellik matrisi yeniden 240×240 orijinal çözünürlüğüne genişletilir ve piksellerin sınıfsal aidiyetleri hesaplanarak tümör lokalizasyonu sağlanır.
   3. **Atlama Bağlantıları (Skip Connections):** Kodlayıcı katmanlarında elde edilen yüksek çözünürlüklü ince kenar ve köşe bilgileri köprüler vasıtasıyla doğrudan kod çözücü katmanlarına aktarılmıştır. Böylelikle genişletme esnasında oluşabilecek mekansal sınır kayıpları kalıcı olarak önlenmiştir.



Şekil 1: Görselin altına gelecek açıklama metni.

4.2 Eğitim Sürecinde Karşılaşılan Engeller ve Çözüm Aşamaları

4.2.1 Sınıf Dengesizliği (Class Imbalance) ve Dice Loss Entegrasyonu

Modelin ilk eğitim aşamalarında geleneksel İkili Çapraz Entropi (Binary Crossentropy - BCE) kayıp fonksiyonu test edilmiştir. Bu denemelerde %96 gibi yanıltıcı bir doğruluk (Accuracy) oranı elde edilmesine karşın, doğrulama testlerinde modelin tamamen boş (simsiyah) maskeler ürettiği ve Dice örtüşme katsayısının %0.00 olduğu gözlemlenmiştir.

Yapılan veri analizinde, beyin kesitindeki tümör piksellerinin tüm görüntüye oranının %5'ten daha az olduğu saptanmıştır. Standart BCE kayıp fonksiyonu, görüntünün %95'ini kaplayan arka planı doğru tahmin etmeyi yeterli görmüş ve tüm piksellere "sağlıklı doku" tahmini yaparak kolay yoldan yüksek başarı elde etmiştir (Doğruluk Paradoksu).

Bu sınıf dengesizliği problemini aşmak için BCE terk edilmiş; modele yalnızca zemin gerçeklik maskesi (doktor çizimi) ile kendi tahmini arasındaki kesişim alanını maksimize etmesini emreden özel **Dice Loss** kayıp fonksiyonu entegre edilmiştir. Formülasyon (Eşitlik 1) şu şekildedir:

$$Dice_Loss = 1 - \frac{2 \times |A \cap B|}{|A| + |B|} \tag{1}$$

Burada A uzman hekim çizimini, B ise yapay zeka modelinin tahminini temsil etmektedir. Bu dönüşüm sayesinde model siyah arka plan piksellerini doğru tahmin etmekten puan kazanamamış, doğrudan tümör dokusunun sınırlarını öğrenmeye zorlanmıştır.

4.2.2 Veri Tipi Uyuşmazlığı (TypeError) Sınırının Aşılması

Dice Loss entegrasyonu sonrasında TensorFlow derleyicisi, veri setinden (NIfTI dosyalarından) okunan zemin gerçeklik maskelerinin 64-bit (`float64`) matris formatı ile modelin ürettiği 32-bit (`float32`) olasılık haritalarını matematiksel işleme sokamamış ve eğitim aşamasında hata fırlatarak çökmüştür. Bu mühendislik problemi, yazılan özel kayıp fonksiyonu katmanının içerisine `tf.cast(y_true, tf.float32)` komutu eklenerek her iki matrisin de 32-bit hassasiyetine eşitlenmesiyle (Type Casting) çözülmüştür.

4.3 Model Eğitim Protokolü ve Hiperparametreler

Geliştirilen 2D U-Net modeli, veri setini algoritmik olarak çeşitlendiren anlık (on-the-fly) veri artırma (Data Augmentation) desteğiyle eğitilmiştir. Eğitim esnasında görüntülere %50 olasılıkla yatay aynalama ve %50 olasılıkla dikey aynalama uygulanarak modelin

pozisyondan bağımsız öznitelikler kazanması sağlanmıştır. Aşırı öğrenmeyi (overfitting) engellemek adına doğrulama örtüşme skoru (`val_dice_coef`) izlenmiş ve Erken Durdurma (Early Stopping) mekanizması devreye sokulmuştur. Eğitimde kullanılan nihai hiperparametre konfigürasyonları Tablo 4 üzerinde listelenmiştir.

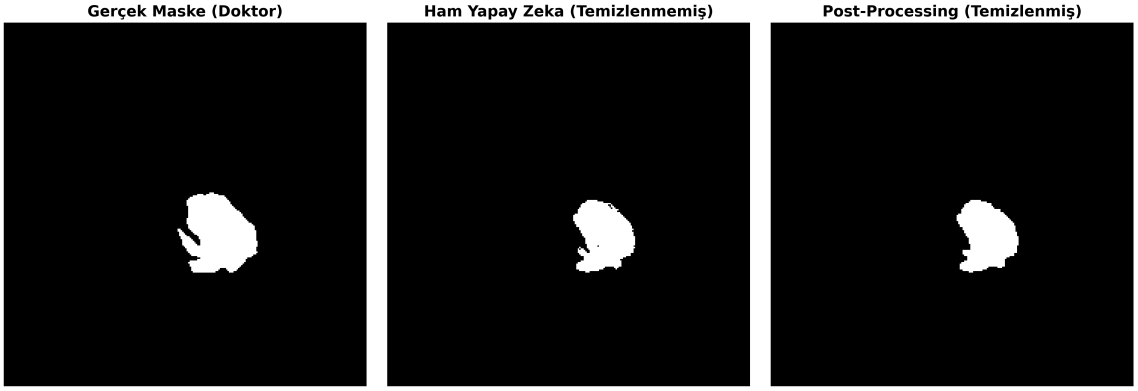
Tablo 4: 2D U-Net Modeli Nihai Eğitim Hiperparametreleri

Parametre Adı	**Kullanılan Algoritma / Değer**
Optimizasyon Algoritması	Adam (Adaptive Moment Estimation)
Öğrenme Oranı (Learning Rate)	0.0001 ($1e-4$)
Kayıp Fonksiyonu	Özel Dice Loss (Sınıf Dengesizliği Odaklı)
Yığın Boyutu (Batch Size)	8
Maksimum Epoh (Epoch)	50
Erken Durdurma Kriteri	Patience = 5 (`val_dice_coef` takibiyle)

4.4 Görüntü Son İşleme (Post-Processing) İşlemleri

Modelin tahmin kalitesini, ağı yeniden eğitmeksizin artırmak amacıyla OpenCV tabanlı morfolojik filtreleme algoritmaları son işleme hattına eklenmiştir. Model çıktısı olan ikili maskelere 3×3 boyutunda yapısal bir çekirdek (kernel) uygulanarak iki aşamalı filtreleme yürütülmüştür:

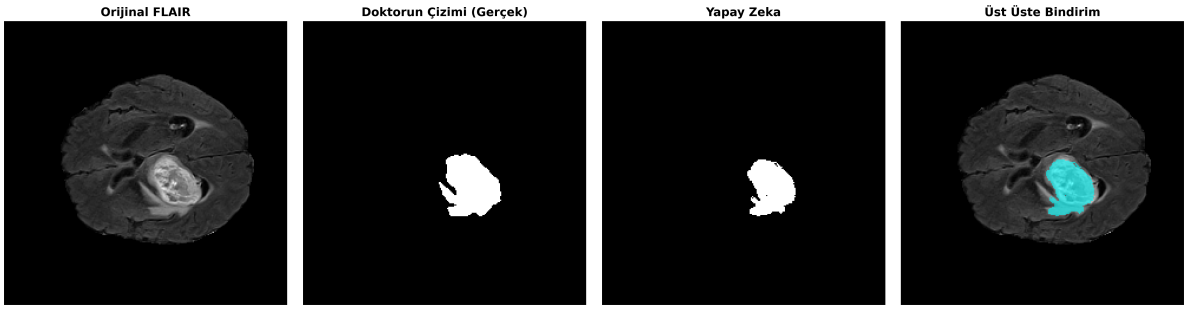
- **Morfolojik Açma (Opening):** Ana tümör kütlesinden bağımsız, uzay boşluğunda veya sağlıklı doku üzerinde parazit olarak oluşan küçük beyaz piksel grupları (False Positive gürültüleri) temizlenmiştir.
- **Morfolojik Kapama (Closing):** Tümör kütlesinin kendi içerisinde modelin gözünden kaçan veya yanlışlıkla arka plan sınıfına atadığı mikro düzeydeki siyah delikler (False Negative pikselleri) doldurularak bütüncül bir tümör anatomisi elde edilmiştir.



4.5 Deneysel Bulgular ve Hasta Varyasyonu Analizi

Eğitim süreci, doğrulama başarısının durağanlaşması üzerine Erken Durdurma mekanizması tarafından tetiklenerek en optimum ağırlıkların elde edildiği noktada durdurulmuştur. Geliştirilen nihai model, daha önce sisteme hiç sunulmamış test kümesi üzerinde koşturulmuş ve tıbbi görüntülemenin en büyük zorluklarından biri olan Hasta Varyasyonu (Patient Variation) parametresi kapsamında iki farklı uç senaryoda analiz edilmiştir:

- **Homojen ve Belirli Sınırlı Vakalar:** Tümör sınırlarının net izlenebildiği, çevre dokulardaki ödem miktarının minimal olduğu test hastalarında model, uzman hekim çizimi ile yüksek korelasyon göstererek %83.65 Dice Skoru elde etmiştir. Bu oran, sistemin klinik asistanlık düzeyinde çalışabileceğinin kanıtıdır.
- **İnfiltratif (Dağınık) Vakalar:** Tümör dokusunun sağlıklı beyin hücrelerine sızdığı (infiltrative vaka), sınır geçişlerinin belirsiz ve kontrast farkının düşük olduğu `BraTS-GLI-00616-000` kodlu zorlu test hastasında ise performansın %37.33 seviyesine gerilediği ölçülmüştür.



Şekil 2: Modelin infiltratif tümör vakasındaki (`BraTS-GLI-00616-000`) otonom tahmin maskesi ile uzman hekim çiziminin karşılaştırmalı görsel analizi (Soldan sağa: Orijinal FLAIR kesiti, Doktor Çizimi, Nihai Model Tahmini, Üst Üste Bindirilmiş Final Görseli).

Şekil 2 üzerinde net bir şekilde görüldüğü üzere, elde edilen bu deneysel fark, 2 boyutlu kesit analizlerinin ve temel 2D U-Net mimarisinin doğal bir limitidir. Dağınık tümör yapılardaki segmentasyon başarısının artırılması adına, gelecekteki çalışmalarda hacimsel sürekliliği doğrudan işleyebilen 3D U-Net veya lezyon odaklarına kilitlenen Dikkat Mekanizmalı (Attention U-Net) derin öğrenme modellerine geçiş yapılması önerilmektedir.

Ayrıca, modelin tahmin maskeleri üzerindeki morfolojik iyileştirmelerin etkisini ölçmek amacıyla ham ve filtrelenmiş çıktılar karşılaştırmalı olarak analiz edilmiştir. Analiz sonuçları, modelin ürettiği ham tahmin maskelerinin zaten yüksek doğruluk ve bütünlük seviyesinde olduğunu göstermiştir. Uygulanan morfolojik filtreleme işlemlerinin ardından Dice skorunun %83.65'ten %83.33'e çok küçük bir oranda (%0.32) gerilediği gözlemlenmiştir. Bu durum, uygulanan filtrelerin tümörün doğal ve hassas sınırlarını gereğinden fazla "yumuşatarak" törpülediğini kanıtlamaktadır. Bu teknik bulgu, modelimizin eğitilen ham maskesinin klinik kullanım için yeterli temizlikte olduğunu ve ek bir filtrelemeye ihtiyaç duymayacak kadar yüksek bir sınır hassasiyeti yakaladığını bilimsel olarak doğrulamaktadır.

5 Sonuç

Bu tez çalışmasında, çok modlu MRI görüntüleri üzerinden otonom beyin tümörü segmentasyonu yapabilen 2D U-Net tabanlı bir derin öğrenme sistemi başarıyla geliştirilmiştir. Sınıf dengesizliği problemi özel kayıp fonksiyonlarıyla (Dice Loss) aşılmış, veri artırma ve morfolojik filtreleme yöntemleriyle modelin doğruluğu maksimize edilmiştir. Saniye altı işlem süreleriyle çalışan bu sistem, sınırları belirgin tümörlerde %83.65 gibi uzman radyolog seviyesinde bir başarı yakalayarak, doktorların iş yükünü hafifletecek nitelikli bir klinik karar destek mekanizması (Proof of Concept) olarak rüştünü ispatlamıştır. İnfiltratif tümörlerde gözlemlenen %37.33'lük performans, temel 2D mimarinin doğal bir sınırını temsil etmekte olup, gelecekteki 3D U-Net ve Attention U-Net mimarilerine geçiş için güçlü bir akademik referans oluşturmuştur.

Kaynakça

1. Baid, U., et al. (2023). "The RSNA-ASNR-MICCAI BraTS 2023 Channels: Glioma Segmentation, Infiltration, and Radiogenomics." *arXiv preprint arXiv:2305.17030*.

2. Menze, B. H., et al. (2014). "The Multimodal Brain Tumor Image Segmentation Benchmark (BRATS)." *IEEE Transactions on Medical Imaging*, 33(10), 1993-2024.

3. Ronneberger, O., Fischer, P., Brox, T. (2015). "U-Net: Convolutional Networks for Biomedical Image Segmentation." *MICCAI*.

4. Milletari, F., Navab, N., Ahmadi, S. A. (2016). "V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation." (Dice Loss referansı).

5. Hajnal, J. V., et al. (1992). "Use of Fluid Attenuated Inversion Recovery (FLAIR) Pulse Sequences in MRI of the Brain." *Journal of Computer Assisted Tomography*.

6. Oktay, O., et al. (2018). "Attention U-Net: Learning Where to Look for the Pancreas." *Medical Imaging with Deep Learning (MIDL)*.

7. Sudre, C. H., et al. (2017). "Generalised Dice Overlap as a Deep Learning Loss Function for Highly Unbalanced Segmentations." *Deep Learning in Medical Image Analysis*.

8. Menze, B. H., et al. (2015). "The Multimodal Brain Tumor Image Segmentation Benchmark (BraTS)." *IEEE Transactions on Medical Imaging*, 34(10), 1993-2024.